

Relatório Técnico - GAIE

Projeto: OceanMind - Inteligência Oceânica e Previsão Climática via Dados Espaciais

Disciplina: Generative AI For Engineering (GAIE)

Global Solution: 2026 - Indústria Espacial: O Código que Move o Universo

Curso: Engenharia de Software - 4º ano

Repositório: <https://github.com/pedrobicas/oceanmind-gaie-ml>

Aplicação: <https://oceanmind-gaie-ml.streamlit.app>

1. Integrantes

Nome	RM
Bryan Willian	551305
Felipe Terra	99405
Gabriel Doms	98630
Lucas Vassão	98607
Pedro Bicas	99534

2. Contexto

O OceanMind é uma solução voltada ao monitoramento de riscos oceânicos e costeiros. A ideia é usar dados ambientais, climáticos e espaciais para indicar quando uma região marítima apresenta maior risco.

Nesta parte da Global Solution, o foco foi criar um pipeline de Machine Learning para classificar o risco oceânico. A solução se conecta ao tema da Indústria Espacial porque trabalha com dados inspirados em observação terrestre e sensoriamento remoto, que são comuns em aplicações com satélites.

3. Objetivo

O objetivo do modelo é prever o campo:

```
ocean_risk_level
```

As classes são:

- baixo
- moderado
- alto
- critico

4. Dados

Foi criado um dataset sintético com 1.600 registros e 15 colunas. A geração foi feita em Python, no arquivo:

```
src/generate_dataset.py
```

O CSV usado no treinamento está em:

data/oceanmind_dataset.csv

As variáveis simulam condições oceânicas e climáticas, como temperatura da superfície do mar, anomalia térmica, vento, ondas, umidade, pressão atmosférica, nuvens, clorofila e velocidade da corrente.

Distribuição das classes:

Classe	Registros
moderado	431
baixo	394
critico	390
alto	385

5. Metodologia

O pipeline foi implementado com `scikit-learn`. A coluna `sample_id` foi removida por ser apenas um identificador, e a variável alvo foi separada dos atributos.

A base foi dividida em treino e teste com estratificação, mantendo a distribuição das classes. Para o pré-processamento, foram usadas duas etapas:

- `StandardScaler` para as variáveis numéricas;
- `OneHotEncoder` para a variável categórica `region`.

Depois disso, foram treinados dois modelos de classificação:

- `Random Forest Classifier`;
- `Gradient Boosting Classifier`.

Os modelos foram avaliados com acurácia, precision, recall, f1-score e matriz de confusão.

6. Resultados

Resultados obtidos no conjunto de teste:

Modelo	Acurácia
Random Forest	80,625%
Gradient Boosting	80,3125%

O Random Forest teve a melhor acurácia e foi escolhido como modelo final.

Arquivos gerados:

```
models/random_forest.joblib
models/gradient_boosting.joblib
models/best_model.joblib
reports/metrics.json
reports/figures/confusion_matrix_random_forest.png
reports/figures/confusion_matrix_gradient_boosting.png
```

7. SHAP

Foi usada a biblioteca SHAP para interpretar o modelo final. Como o problema possui mais de uma classe, a importância foi agregada pela média absoluta dos valores SHAP.

Principais variáveis:

Posição	Variável	Importância SHAP
1	temperature_anomaly_c	0.1471
2	sea_surface_temperature_c	0.0602
3	wave_height_m	0.0289
4	wind_speed_kmh	0.0221
5	pressure_hpa	0.0209

A variável mais importante foi a anomalia térmica. Isso é coerente com o problema, porque alterações anormais na temperatura do mar podem indicar instabilidade climática e risco ambiental maior.

Arquivos:

```
reports/shap_ranking.json
reports/figures/shap_feature_importance.png
```

8. Aplicação

A aplicação foi desenvolvida em Streamlit, no arquivo:

```
app.py
```

Ela permite escolher uma região, ajustar os indicadores ambientais e consultar o nível de risco previsto pelo modelo. Também mostra as métricas de treinamento e as variáveis mais importantes segundo SHAP.

Aplicação publicada:

```
https://oceanmind-gaie-ml.streamlit.app
```

9. Como Reproduzir

```
python -m venv .venv
.venv\Scripts\activate
pip install -r requirements.txt
python src/train_models.py
python src/shap_analysis.py
streamlit run app.py
```

10. Conclusão

O projeto entregou um pipeline completo de Machine Learning para classificação de risco oceânico, com geração de dados, pré-processamento, comparação de modelos, avaliação, SHAP e aplicação publicada em Streamlit.

O resultado final ficou integrado ao tema da Global Solution por usar dados ambientais e espaciais simulados para apoiar decisões em regiões marítimas e costeiras.